LAPORAN PROJECT BIG DATA ANALYTICS

MENGGUNAKAN PYSPARK

ANALISIS DATASET SPOTIFY TRACKS MENGGUNAKAN PYSPARK DENGAN ALGORITMA K-MEANS

Disusun oleh:

Nasrulloh Arriziq (221351106)

Kelas : Pagi A

Mata Kuliah : Big Data Analytics

Program Studi : Teknik Informatika

Dosen Pengampu : Dayan Singasatia, S.kom, M.kom

Tahun Akademik : 2025/2026

BAB I
PENDAHULUAN

1.1 Latar Belakang

Analisis data berperan penting dalam mendukung pengambilan keputusan karena mampu mengubah data menjadi informasi yang bermanfaat. Dengan memanfaatkan teknik analitik, pola dan karakteristik data dapat diidentifikasi untuk menghasilkan insight yang mendukung proses pengambilan keputusan.

Pada proyek ini digunakan Spotify Tracks Dataset karena memuat berbagai informasi mengenai lagu, seperti popularitas, genre, danceability, energy, dan tempo. Dataset ini dipilih karena sesuai untuk penerapan PySpark dalam proses pengolahan data, analisis, serta pengelompokan lagu menggunakan algoritma K-Means.

1.2 Tujuan Proyek

Tujuan dari pelaksanaan proyek Big Data Analytics menggunakan PySpark adalah sebagai berikut.

1. Mengolah Spotify Tracks Dataset menggunakan framework PySpark sebagai platform analisis Big Data.
2. Melakukan proses data cleaning yang meliputi penanganan missing value, penghapusan data duplikat, serta penyesuaian tipe data agar siap digunakan pada proses analisis.
3. Melakukan exploratory data analysis (EDA) untuk memperoleh informasi mengenai distribusi genre musik, tingkat popularitas lagu, karakteristik artis, distribusi lagu explicit, serta karakteristik audio lagu populer.
4. Membangun model machine learning sederhana menggunakan algoritma K-Means Clustering pada Spark MLlib untuk mengelompokkan lagu berdasarkan kemiripan karakteristik audio.
5. Menghasilkan insight serta rekomendasi yang dapat dimanfaatkan dalam mendukung pengambilan keputusan pada bidang layanan streaming musik dan sistem rekomendasi lagu.

BAB II
DATA DAN METODOLOGI

2.1 Dataset

Nama Dataset: **Spotify Tracks Dataset**

Link Dataset (GoogleDrive):

https://drive.google.com/file/d/11mxBQv6pNZ4YzrRS3rRO0aPE0yaJdAn_/view?usp=sharing

Sumber Dataset: Spotify Tracks Dataset, Kaggle. Tersedia pada: https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset

Jumlah Data: Dataset terdiri dari **114.000** data lagu (tracks)

Deskripsi Variabel:

Tabel 2. 1 Deskripsi Variabel

Variabel	Deskripsi
Id	Nomor indeks setiap data lagu.
track_id	Identitas unik lagu pada Spotify.
Artists	Nama artis atau penyanyi yang membawakan lagu.
album_name	Nama album tempat lagu dirilis
track_name	Judul lagu.
Popularity	Tingkat popularitas lagu dengan rentang nilai 0–100.
duration_ms	Durasi lagu dalam satuan milidetik.
Explicit	Menunjukkan apakah lagu mengandung konten eksplisit (True/False).
Danceability	Tingkat kemudahan lagu untuk digunakan sebagai musik dansa (0–1).
energy	Tingkat energi lagu berdasarkan intensitas dan aktivitas musik (0–1).
key	Tangga nada utama lagu (0–11).
loudness	Tingkat kekerasan suara lagu dalam satuan desibel (dB).
mode	Mode musik, yaitu mayor (1) atau minor (0).
speechiness	Tingkat dominasi unsur ucapan pada lagu (0–1).

Variabel	Deskripsi
acousticness	Tingkat karakteristik akustik lagu (0–1).
instrumentalness	Probabilitas lagu merupakan musik instrumental (0–1).
liveness	Indikasi apakah lagu direkam secara live (0–1).
valence	Tingkat nuansa positif atau kebahagiaan yang dimiliki lagu (0–1).
tempo	Kecepatan lagu dalam satuan Beats Per Minute (BPM).
time_signature	Jumlah ketukan dalam satu birama lagu.
track_genre	Genre musik dari setiap lagu.

2.2 Tools yang Digunakan

Pelaksanaan proyek Big Data Analytics ini menggunakan beberapa perangkat lunak dan pustaka (library) sebagai berikut.

1. **Google Colab** sebagai lingkungan pengembangan berbasis cloud untuk menjalankan notebook Python.
2. **Apache Spark (PySpark)** sebagai framework utama dalam pemrosesan dan analisis data berskala besar.
3. **Spark MLlib** sebagai library machine learning untuk membangun model K-Means Clustering.
4. **Matplotlib** untuk membuat visualisasi hasil analisis data.
5. **Pandas** untuk mengubah sebagian hasil analisis PySpark menjadi DataFrame yang digunakan pada proses visualisasi.

2.3 Tahapan Analisis

Tahapan penelitian pada proyek ini dilakukan secara sistematis menggunakan pendekatan Big Data Analytics berbasis PySpark. Alur analisis terdiri atas lima tahapan utama sebagai berikut.

1. Data Understanding

Tahap pertama dilakukan dengan mengimpor dataset Spotify ke dalam PySpark, kemudian melakukan identifikasi jumlah data, jumlah atribut, struktur

data (schema), serta statistik deskriptif untuk memperoleh gambaran umum mengenai karakteristik dataset.

2. Data Cleaning

Tahap data cleaning bertujuan untuk meningkatkan kualitas data sebelum dilakukan analisis. Proses yang dilakukan meliputi pemeriksaan missing value, penghapusan data duplikat, perubahan tipe data menggunakan fungsi try_cast(), serta penghapusan data yang tidak valid sehingga seluruh atribut numerik siap digunakan pada proses analisis dan machine learning.

3. Exploratory Data Analysis (EDA)

Tahap EDA dilakukan untuk memperoleh informasi penting mengenai dataset melalui beberapa analisis, yaitu:

1. Analisis jumlah lagu pada setiap genre.
2. Analisis rata-rata popularitas berdasarkan genre.
3. Analisis distribusi lagu explicit dan non-explicit.
4. Analisis artis dengan jumlah lagu terbanyak.
5. Analisis karakteristik audio pada lagu dengan tingkat popularitas tinggi.

Seluruh hasil analisis divisualisasikan menggunakan grafik sehingga lebih mudah dipahami.

4. Machine Learning

Pada tahap ini diterapkan algoritma **K-Means Clustering** menggunakan Spark MLlib. Sebelum proses clustering dilakukan, data dipersiapkan menggunakan **VectorAssembler** untuk menggabungkan atribut numerik menjadi satu vektor fitur, kemudian dilakukan normalisasi menggunakan **StandardScaler**. Jumlah cluster ditentukan menggunakan **Elbow Method**, sedangkan kualitas hasil clustering dievaluasi menggunakan **Silhouette Score**.

5. Insight dan Rekomendasi

Tahap terakhir dilakukan dengan menginterpretasikan seluruh hasil analisis data dan hasil clustering sehingga diperoleh beberapa insight utama mengenai karakteristik lagu pada dataset Spotify. Berdasarkan insight tersebut disusun rekomendasi yang dapat dimanfaatkan sebagai dasar pengambilan keputusan, khususnya dalam pengembangan sistem rekomendasi musik, strategi promosi lagu, dan pengelolaan katalog musik digital.

BAB III
HASIL DAN PEMBAHASAN

3.1 Data Understanding

Tahap pertama dalam proyek ini adalah melakukan **data understanding** terhadap Spotify Tracks Dataset menggunakan PySpark. Tahap ini bertujuan untuk memperoleh gambaran umum mengenai karakteristik dataset sebelum dilakukan proses pembersihan data maupun analisis lebih lanjut.

Dataset diimpor ke dalam lingkungan Apache Spark menggunakan fungsi spark.read.csv() dengan opsi header=True sehingga nama setiap kolom dapat dikenali secara otomatis. Selanjutnya dilakukan pemeriksaan jumlah baris dan kolom, struktur data (schema), serta statistik deskriptif untuk mengetahui karakteristik setiap atribut.

```
df = spark.read \
    .option("header", True) \
    .option("quote", '"') \
    .option("escape", '"') \
    .option("multiLine", False) \
    .csv("/content/dataset.csv")
```

Gambar 3. 1 Import Dataset

```
df.printSchema()
```

```
root
 |-- _c0: string (nullable = true)
 |-- track_id: string (nullable = true)
 |-- artists: string (nullable = true)
 |-- album_name: string (nullable = true)
 |-- track_name: string (nullable = true)
 |-- popularity: string (nullable = true)
 |-- duration_ms: string (nullable = true)
 |-- explicit: string (nullable = true)
 |-- danceability: string (nullable = true)
 |-- energy: string (nullable = true)
 |-- key: string (nullable = true)
 |-- loudness: string (nullable = true)
 |-- mode: string (nullable = true)
 |-- speechiness: string (nullable = true)
 |-- acousticness: string (nullable = true)
 |-- instrumentalness: string (nullable = true)
 |-- liveness: string (nullable = true)
 |-- valence: string (nullable = true)
 |-- tempo: string (nullable = true)
 |-- time_signature: string (nullable = true)
 |-- track_genre: string (nullable = true)
```

Gambar 3. 2 Skema

```
print("Jumlah Baris :", df.count())
print("Jumlah Kolom :", len(df.columns))
```

```
Jumlah Baris : 114000
Jumlah Kolom : 21
```

Gambar 3. 3 Jumlah Baris dan Kolom

```
df.describe().show()
```

```
+-------+-----------------+--------------------+----------+--------------------+--------------------+------------------+-----------+
|summary|              _c0|            track_id|   artists|          album_name|          track_name|        popularity|       dura|
+-------+-----------------+--------------------+----------+--------------------+--------------------+------------------+-----------+
|  count|           114000|              114000|    113999|              113999|              113999|            114000|           |
|   mean|          56999.5|                NULL|6270.33333333333|            Infinity|            Infinity| 33.2385350877193|228029.1531|
| stddev|32909.10968105944|                NULL|18996.35858765856|                 NaN|                 NaN|22.30507849337221|107297.7126|
|    min|                0|0000vdREvCVMxbQTk...|    !nvite|       ! ! ! ! ! Whisper...|!I'll Be Back!|                 0|           |
|    max|            99999|7zz7iNGIWhmfFE7zl...|        龍藏Ryuzo|당신이 잠든 사이에 Pt. 4 ...| 행복하길 바래|                99|          9|
+-------+-----------------+--------------------+----------+--------------------+--------------------+------------------+-----------+
```

Gambar 3. 4 Statistik Deskriptif

Pembahasan

Berdasarkan proses data understanding, diperoleh dataset Spotify Tracks yang terdiri dari 114.000 lagu dengan 21 atribut. Beberapa atribut numerik masih bertipe string sehingga perlu dikonversi sebelum analisis. Statistik deskriptif digunakan untuk memahami karakteristik data dan memastikan dataset siap digunakan pada tahap berikutnya.

3.2 Data Cleaning

Tahap data cleaning dilakukan untuk meningkatkan kualitas dataset sehingga data yang digunakan pada proses analisis dan machine learning memiliki konsistensi serta validitas yang lebih baik. Tahapan ini meliputi pemeriksaan missing value, penghapusan data duplikat, konversi tipe data, serta penanganan data yang tidak valid.

Langkah-langkah data cleaning yang dilakukan adalah sebagai berikut.

1. Mengubah nama kolom indeks menjadi **id** agar lebih mudah dipahami.
2. Melakukan konversi tipe data menggunakan fungsi try_cast() pada atribut numerik.
3. Melakukan pemeriksaan missing value pada setiap atribut.

4. Menghapus data duplikat menggunakan fungsi dropDuplicates().
5. Menghapus data yang gagal dikonversi atau memiliki nilai tidak valid pada atribut numerik.

Tahap ini dilakukan untuk mengubah nama kolom _c0 menjadi id agar lebih mudah dipahami dan mempermudah proses analisis selanjutnya.

```
df = df.withColumnRenamed("_c0", "id")
```

Gambar 3. 5 Mengubah Nama Kolom

Tahap ini bertujuan untuk mengetahui jumlah nilai kosong pada setiap atribut sehingga dapat ditentukan metode penanganannya sebelum proses analisis dilakukan.

```
from pyspark.sql.functions import col, count, when

missing = df.select([
    count(when(col(c).isNull() | (col(c) == ""), c)).alias(c)
    for c in df.columns
])

missing.show(truncate=False)
```

```
+---+--------+-------+----------+----------+----------+-----------+--------+------------+------+---+--------+----+-------------+------------+--
|id |track_id|artists|album_name|track_name|popularity|duration_ms|explicit|danceability|energy|key|loudness|mode|speechiness|acousticness|ir
+---+--------+-------+----------+----------+----------+-----------+--------+------------+------+---+--------+----+-------------+------------+--
|0  |0       |1      |1         |1         |0         |0          |0       |0           |0     |0  |0       |0   |0            |0           |0
+---+--------+-------+----------+----------+----------+-----------+--------+------------+------+---+--------+----+-------------+------------+--
```

Gambar 3. 6 Pemeriksaan Missing Value

Seluruh baris yang masih memiliki nilai kosong dihapus agar dataset yang digunakan pada proses analisis memiliki data yang lengkap dan konsisten.

```
df = df.dropna(subset=list(numeric_columns.keys()))
```

Gambar 3. 7 Menghapus Missing Value

Proses ini dilakukan untuk menghilangkan data yang muncul lebih dari satu kali sehingga hasil analisis tidak dipengaruhi oleh data yang berulang.

```
print("Sebelum:", df.count())

df = df.dropDuplicates()

print("Sesudah:", df.count())
```

```
Sebelum: 114000
Sesudah: 114000
```

Gambar 3. 8 Menghapus Data Duplikat

Setelah seluruh proses pembersihan selesai dilakukan, struktur dataset diperiksa kembali untuk memastikan setiap atribut telah memiliki tipe data yang sesuai dan siap digunakan pada tahap analisis berikutnya.

```
df.printSchema()
```

```
root
 |-- id: string (nullable = true)
 |-- track_id: string (nullable = true)
 |-- artists: string (nullable = true)
 |-- album_name: string (nullable = true)
 |-- track_name: string (nullable = true)
 |-- popularity: integer (nullable = true)
 |-- duration_ms: integer (nullable = true)
 |-- explicit: string (nullable = true)
 |-- danceability: double (nullable = true)
 |-- energy: double (nullable = true)
 |-- key: integer (nullable = true)
 |-- loudness: double (nullable = true)
 |-- mode: integer (nullable = true)
 |-- speechiness: double (nullable = true)
 |-- acousticness: double (nullable = true)
 |-- instrumentalness: double (nullable = true)
 |-- liveness: double (nullable = true)
 |-- valence: double (nullable = true)
 |-- tempo: double (nullable = true)
 |-- time_signature: integer (nullable = true)
 |-- track_genre: string (nullable = true)
```

Gambar 3. 9 Skema

Tabel 3. 1 Perbandingan Sebelum dan Sesudah Cleaning

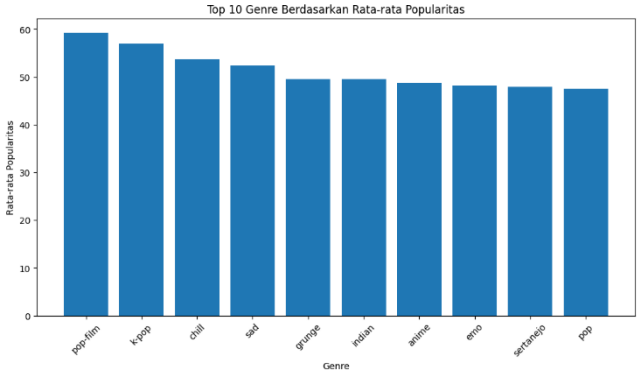
Keterangan	**Jumlah Data**
Sebelum Cleaning	114.000
Setelah Cleaning	114.000

Pembahasan

Hasil data cleaning menunjukkan bahwa dataset telah berhasil dipersiapkan untuk proses analisis lebih lanjut. Seluruh atribut numerik telah memiliki tipe data yang sesuai sehingga dapat digunakan pada proses perhitungan statistik maupun algoritma machine learning. Selain itu, data duplikat berhasil dihapus dan data yang tidak valid telah dieliminasi sehingga kualitas dataset menjadi lebih baik dan menghasilkan analisis yang lebih akurat.

3.3 Analisis Data

1. Analisis Rata-rata Popularitas Lagu Berdasarkan Genre

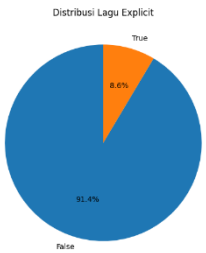


Gambar 3. 10 Grafik Rata-rata Popularitas Lagu Berdasarkan Genre

Interpretasi

Genre **pop-film** memiliki rata-rata popularitas tertinggi (59,283), diikuti **k-pop** dan **chill**. Hasil ini menunjukkan bahwa tingkat popularitas berbeda pada setiap genre dan dapat menjadi referensi dalam penyusunan rekomendasi maupun promosi musik.

2. Analisis Distribusi Lagu Explicit dan Non-Explicit



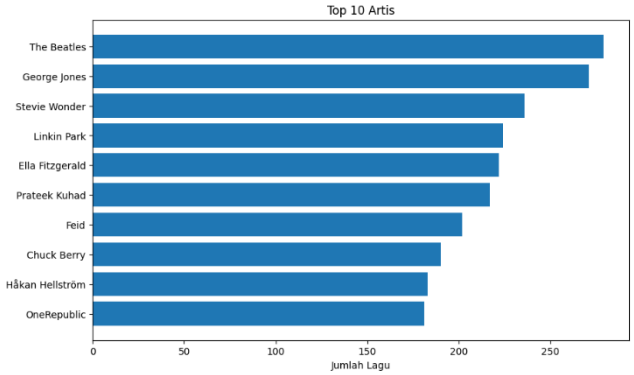
Gambar 3. 11 Distribbusi Lagu Explicit

Interpretasi

Sebagian besar lagu pada dataset merupakan **non-explicit (91,4%)**, sedangkan lagu explicit hanya **8,6%**. Hal ini menunjukkan bahwa mayoritas lagu pada dataset aman didengarkan oleh berbagai kalangan.

3. Analisis Top 10 Artis dengan Jumlah Lagu Terbanyak

Analisis ini bertujuan untuk mengidentifikasi artis yang memiliki jumlah lagu terbanyak dalam Spotify Tracks Dataset. Hasil analisis dapat memberikan gambaran mengenai artis yang memiliki representasi lagu paling banyak pada dataset.

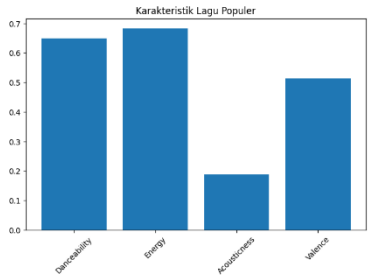


Gambar 3. 12 Grafik Top 10 Artis dengan Jumlah Lagu Terbanyak

Interpretasi

The Beatles merupakan artis dengan jumlah lagu terbanyak pada dataset, diikuti George Jones dan Stevie Wonder. Hal ini menunjukkan bahwa distribusi jumlah lagu antarartis tidak merata.

4. Analisis Karakteristik Lagu Populer

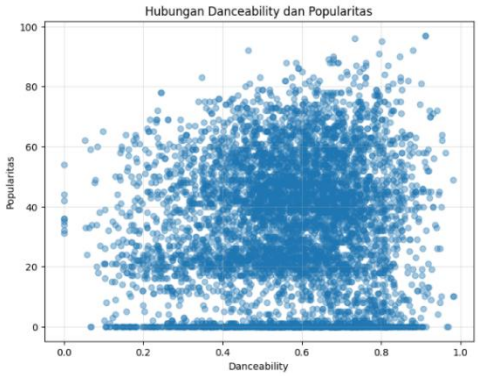


Gambar 3. 13 Grafik Karakteristik Lagu Popoler

Interpretasi

Lagu populer memiliki nilai **energy** dan **danceability** yang relatif tinggi, sedangkan **acousticness** cenderung rendah. Hal ini menunjukkan bahwa lagu populer umumnya bersifat energik dan mudah dinikmati.

5. Analisis Hubungan Danceability dan Popularitas



Gambar 3. 14 Grafik Hubungan Danceabillity dan Popularitas

Interpretasi

Scatter plot menunjukkan bahwa hubungan antara **danceability** dan **popularitas** tidak terlalu kuat. Lagu dengan danceability tinggi belum tentu memiliki popularitas tinggi sehingga terdapat faktor lain yang turut memengaruhi popularitas lagu.

3.4 Machine Learning

Metode yang digunakan: **K-Means Clustering** menggunakan **Spark MLlib**.

Langkah-langkah:

a. Persiapan Data

```
feature_cols = [
    "popularity",
    "danceability",
    "energy",
    "acousticness",
    "instrumentalness",
    "liveness",
    "valence",
    "tempo"
]

ml_df = df.select(feature_cols)
ml_df.show(5)
```

Gambar 3. 15 Memilih Fitur

```
from pyspark.ml.feature import VectorAssembler

assembler = VectorAssembler(
    inputCols=feature_cols,
    outputCol="features"
)

assembled_df = assembler.transform(ml_df)

assembled_df.select("features").show(5, truncate=False)
```

Gambar 3. 16 Menggabungkan Fitur

```
from pyspark.ml.feature import StandardScaler

scaler = StandardScaler(
    inputCol="features",
    outputCol="scaledFeatures",
    withMean=True,
    withStd=True
)

scaler_model = scaler.fit(assembled_df)

scaled_df = scaler_model.transform(assembled_df)

scaled_df.select("scaledFeatures").show(5, truncate=False)
```

Gambar 3. 17 Standarasisasi Data

b. Training Model

```
kmeans = KMeans(
    featuresCol="scaledFeatures",
    predictionCol="cluster",
    k=4,
    seed=42
)

model = kmeans.fit(scaled_df)

cluster_df = model.transform(scaled_df)

cluster_df.select("cluster").show(10)
```

Gambar 3. 18 Training Model Kmeans

c. Hasil Model

```
from pyspark.ml.evaluation import ClusteringEvaluator

evaluator = ClusteringEvaluator(
    featuresCol="scaledFeatures",
    predictionCol="cluster",
    metricName="silhouette"
)

score = evaluator.evaluate(cluster_df)

print("Silhouette Score :", score)
```

```
Silhouette Score : 0.3308393686190979
```

Gambar 3. 19 Silhouette Score

Interpretasi

Nilai **Silhouette Score sebesar 0,3308** menunjukkan bahwa hasil clustering memiliki kualitas yang cukup baik. Nilai ini menunjukkan bahwa setiap cluster memiliki karakteristik yang cukup berbeda sehingga dapat digunakan untuk segmentasi lagu berdasarkan fitur audio.

```
from pyspark.sql.functions import count

cluster_df.groupBy("cluster") \
          .agg(count("*").alias("Jumlah Lagu")) \
          .orderBy("cluster") \
          .show()
```

```
+-------+-----------+
|cluster|Jumlah Lagu|
+-------+-----------+
|      0|        294|
|      1|       2232|
|      2|       1737|
|      3|       1834|
+-------+-----------+
```

Gambar 3. 20 Jumlah Lagu Pada Setiap Cluster

Interpretasi

Cluster 1 memiliki jumlah lagu terbanyak (**2.232 lagu**), sedangkan Cluster 0 memiliki jumlah paling sedikit (**294 lagu**). Perbedaan jumlah anggota merupakan hal yang wajar karena K-Means mengelompokkan data berdasarkan kemiripan karakteristik, bukan jumlah anggota yang sama.

```
from pyspark.sql.functions import avg

cluster_result = cluster_df.select(
    "cluster",
    *feature_cols
)

cluster_result.groupBy("cluster").agg(
    avg("popularity").alias("Avg Popularity"),
    avg("danceability").alias("Avg Danceability"),
    avg("energy").alias("Avg Energy"),
    avg("acousticness").alias("Avg Acousticness"),
    avg("valence").alias("Avg Valence"),
    avg("tempo").alias("Avg Tempo")
).show(truncate=False)
```

```
+-------+------------------+------------------+------------------+-------------------+-------------------+------------------+
|cluster|Avg Popularity    |Avg Danceability  |Avg Energy        |Avg Acousticness   |Avg Valence        |Avg Tempo         |
+-------+------------------+------------------+------------------+-------------------+-------------------+------------------+
|1      |32.681506614572626|0.4519443519089717|0.8281777023785019|0.09270442669545609|0.32476017770237875|138.1342055315647 |
|3      |54.317772192251105|0.6538981118195233|0.6587616325404606|0.2720944195518643 |0.5562692618930853 |116.72771833619451|
|2      |29.10948195723823 |0.4487100566213138|0.2825837892842059|0.7870120170075185 |0.2941188483900964 |109.10768642778599|
|0      |13.130660311229496|0.6826170965933027|0.7280947006869476|0.19951572349081775|0.6820265246039523 |122.81319262582439|
+-------+------------------+------------------+------------------+-------------------+-------------------+------------------+
```

Gambar 3. 21 Profil Setiap Cluster

Interpretasi

Hasil profiling menunjukkan bahwa setiap cluster memiliki karakteristik audio yang berbeda. Cluster 0 didominasi lagu yang mudah ditarikan namun kurang populer. Cluster 1 berisi lagu dengan energy dan tempo tinggi. Cluster 2 didominasi lagu bernuansa akustik dengan energy rendah. Sementara itu, Cluster 3 memiliki rata-rata popularitas tertinggi dengan keseimbangan danceability dan energy yang baik.

```
cluster_pd = (
    cluster_df.groupBy("cluster")
              .count()
              .orderBy("cluster")
              .toPandas()
)

plt.figure(figsize=(6,5))

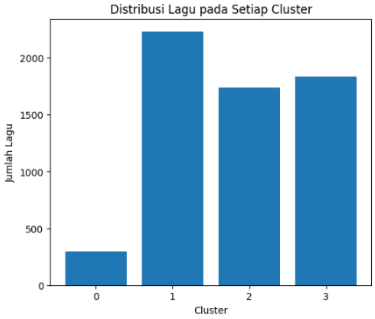
plt.bar(cluster_pd["cluster"].astype(str),
        cluster_pd["count"])

plt.xlabel("Cluster")

plt.ylabel("Jumlah Lagu")

plt.title("Distribusi Lagu pada Setiap Cluster")

plt.show()
```



Gambar 3. 22 Grafik Distribusi Lagu pada Setiap Cluster

Interpretasi Grafik

Distribusi anggota cluster menunjukkan bahwa sebagian besar lagu berada pada Cluster 1, sedangkan Cluster 0 memiliki jumlah anggota paling sedikit. Hal ini menunjukkan bahwa karakteristik lagu pada dataset lebih banyak terkonsentrasi pada Cluster 1.

BAB IV
KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan

Berdasarkan hasil pengolahan data menggunakan PySpark, analisis eksploratif, dan penerapan algoritma K-Means pada dataset Spotify Tracks, dapat disimpulkan sebagai berikut.

1. Proses pengolahan data menggunakan PySpark berhasil dilakukan mulai dari data understanding, data cleaning, EDA, hingga penerapan machine learning.
2. Hasil analisis menunjukkan bahwa setiap genre memiliki tingkat popularitas yang berbeda, mayoritas lagu bersifat non-explicit, dan karakteristik lagu populer cenderung memiliki energy serta danceability yang tinggi.
3. Algoritma K-Means berhasil mengelompokkan lagu menjadi empat cluster dengan **Silhouette Score 0,3308**, sehingga mampu membedakan karakteristik lagu berdasarkan fitur audio.

4.2 Insight

1. Popularitas lagu dipengaruhi oleh kombinasi beberapa fitur audio.
2. Clustering membantu mengelompokkan lagu berdasarkan karakteristik yang serupa.
3. PySpark mempermudah pengolahan dataset berukuran besar.

4.3 Rekomendasi

1. Menambahkan fitur lain agar hasil clustering lebih representatif.
2. Membandingkan K-Means dengan algoritma clustering lain.
3. Menggunakan metrik evaluasi tambahan untuk memperoleh model terbaik.

DAFTAR PUSTAKA

Apache Spark. (2025). *MLlib: DataFrame-based Machine Learning Guide*. https://spark.apache.org/docs/latest/ml-guide.html

Maharshi Pandya. (2022). *Spotify Tracks Dataset*. Kaggle. https://www.kaggle.com/datasets/maharshipandya/spotify-tracks-dataset